

Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la
Recherche Scientifique Université Constantine 2 –
AbdelHamid Mehri



Faculté des Nouvelles Technologies de l'Information
et de la Communication
Département des nouvelles Technologies des
Logiciels et Systèmes d'Information

Option : Science de Données et Systèmes
Intelligents (SDSI)

Mini Project : Exploration du DeepLearning

Détection de Genre (CNN)

Dirigé par :

Mme.Bouleghlimat Imene

Réalisé par :

Derradji Aymene Badreddine

Boumakh Mohamed

Table des matières

1 Introduction au problème	2
1.1 Contexte et importance	2
2 Préparation des données	3
2.1 Description du dataset :	3
2.2 Prétraitement des données :	3
2.3 Justification du choix du dataset :	4
3 Justification de l'approche technique	4
3.1 Choix du modèle : CNN	4
3.2 Sélection des couches	4
3.3 Fonction de perte : BinaryCrossentropy	5
3.4 Optimiseur : Adam	5
4 Discussion des résultats	5
4.1 Performance générale du modèle :	5
4.2 Interprétation des courbes de perte :	5
4.3 Interprétation des courbes de précision :	5
4.4 Description des graphes obtenu :	6
5 Evaluation et test du modèle :	7
6 Conclusion	9

1 Introduction au problème

La prédiction du genre à partir d'images représente une avancée significative dans le domaine de l'intelligence artificielle, en particulier grâce à l'utilisation du Deep Learning. Cette tâche consiste à analyser des images pour identifier des caractéristiques visuelles spécifiques associées au genre, en s'appuyant sur des modèles sophistiqués tels que les réseaux de neurones convolutifs (CNN). Ces réseaux sont capables d'extraire automatiquement des traits complexes à partir d'images, offrant ainsi une alternative puissante aux approches traditionnelles qui nécessitaient des méthodes manuelles de traitement des données.

Dans ce projet, nous nous focalisons sur la classification du genre d'une personne en utilisant des images de son visage. L'objectif principal est de concevoir un modèle de Deep Learning capable d'apprendre à différencier les traits visuels distinctifs des genres à partir d'un ensemble de données d'entraînement. Ce type de classification trouve des applications variées, notamment dans la personnalisation des services (publicités ciblées, recommandations), l'analyse démographique (étude des populations), et les systèmes de sécurité (authentification biométrique et reconnaissance faciale).

Cependant, cette tâche présente également des défis importants. Parmi eux figurent la nécessité de garantir une précision élevée malgré les variations des conditions d'éclairage, des angles de vue, ou des expressions faciales, ainsi que l'évitement des biais éthiques liés aux ensembles de données déséquilibrés. Grâce à ce projet, nous cherchons non seulement à mettre en œuvre un modèle performant, mais également à explorer les solutions aux défis mentionnés, dans le but de développer une application robuste et éthique pour la prédiction du genre.

1.1 Contexte et importance

Applications pratiques :

- Personnalisation : Adapter les services et contenus en fonction du genre présumé (publicités, recommandations).
- Analyse démographique : Comprendre les populations grâce à l'analyse d'images dans divers contextes (surveillance, événements).

-Accessibilité : Améliorer les systèmes de recherche et d'identification dans les domaines de la sécurité et des applications sociales.

Avantages :

- Automatisation des tâches humaines.
- Réduction des erreurs grâce à des modèles de Deep Learning performants.

Défis :

- Éthique : Éviter les biais dans le système.
- Précision : Garantir des données de haute qualité pour de meilleurs résultats.

2 Préparation des données

2.1 Description du dataset :

Pour ce projet, nous avons utilisé le Gender Classification Dataset, accessible sur la plateforme [Kaggle](#). Ce dataset contient des images de visages humains, soigneusement recadrées, permettant une classification binaire entre les genres masculin et féminin. La structure du dataset se divise en deux parties principales : un ensemble d'entraînement comprenant environ 23,000 images pour chaque classe (masculin et féminin) et un ensemble de validation constitué d'environ 5,500 images pour chaque classe. Une caractéristique notable de ce dataset est son équilibre parfait entre les deux classes, ce qui réduit le risque de biais pendant l'entraînement du modèle et garantit une évaluation plus fiable de ses performances. Cette qualité en fait un choix idéal pour développer et tester des modèles de classification du genre.

2.2 Prétraitement des données :

Avant d'entraîner le modèle, les étapes suivantes ont été appliquées aux images :

- 1- Redimensionnement : Toutes les images ont été redimensionnées à une taille uniforme de 48x48 pixels pour correspondre aux exigences du modèle.
- 2- Normalisation : Les valeurs des pixels ont été divisées par 255 pour les ramener à une échelle comprise entre 0 et 1, facilitant ainsi la convergence du modèle.
- 3- Augmentation des données : Non effectuée dans ce projet, mais elle pourrait être envisagée pour améliorer la robustesse du modèle si nécessaire.

Exemple d'images :




Figure 01

2.3 Justification du choix du dataset :

Ce dataset est particulièrement adapté pour ce projet car :

- Il contient un grand nombre d'images (suffisantes pour entraîner un CNN performant).
- Les classes sont équilibrées, minimisant les risques de biais.
- Les images sont déjà recadrées, réduisant le besoin de prétraitement complexe

3 Justification de l'approche technique

3.1 Choix du modèle : CNN

Un CNN est idéal pour l'analyse d'images, car il extrait automatiquement des caractéristiques visuelles (bords, textures) tout en réduisant les paramètres grâce à l'utilisation de noyaux partagés. Cela garantit une efficacité élevée et des performances adaptées à la tâche de classification binaire.

3.2 Sélection des couches

-**Conv2D** : Apprend des motifs visuels avec des noyaux 3x3 et un nombre croissant de filtres (6, puis 16) pour extraire des caractéristiques de plus en plus complexes.

-**MaxPooling2D** : Réduit la taille des données tout en conservant les informations importantes, limitant ainsi le surapprentissage.

-**Dense** : Combine les caractéristiques extraites pour effectuer une classification. Deux couches (1024 et 128 unités) assurent un apprentissage progressif.

Activation ReLU : Introduit de la non-linéarité pour mieux capturer les relations complexes.

3.3 Fonction de perte : BinaryCrossentropy

La BinaryCrossentropy est idéale pour les problèmes de classification binaire. Elle mesure la différence entre les distributions prédites (probabilités générées par le modèle) et les vraies étiquettes (0 ou 1), ce qui permet d'ajuster efficacement les poids du modèle pour réduire l'erreur.

3.4 Optimiseur : Adam

L'optimiseur Adam est choisi pour sa capacité à ajuster dynamiquement le taux d'apprentissage, ce qui accélère la convergence tout en étant robuste aux variations des données.

4 Discussion des résultats

4.1 Performance générale du modèle :

Le modèle montre une bonne capacité d'apprentissage, avec une diminution régulière de la perte et une précision atteignant environ 96 % pour l'entraînement et la validation. Ces résultats indiquent une bonne capacité à faire des prédictions précises.

4.2 Interprétation des courbes de perte :

La perte d'entraînement diminue de façon constante, démontrant une bonne adaptation aux données. Cependant, les légères fluctuations de la perte de validation pourraient être dues à une faible taille de l'ensemble de validation ou à une sensibilité accrue du modèle dans les dernières époques.

4.3 Interprétation des courbes de précision :

L'évolution des courbes montre une amélioration stable de la précision, avec une performance élevée. Les fluctuations sur la courbe de validation restent normales mais peuvent signaler un ajustement trop spécifique du modèle aux données d'entraînement, ce qui pourrait limiter légèrement sa généralisation.

4.4 Description des graphes obtenu :

Graphe de perte(loss)

Le graphique des pertes montre une diminution progressive de la perte d'entraînement, ce qui indique que le modèle apprend efficacement au fil des époques. La perte de validation suit une tendance similaire, mais avec des fluctuations notables, en particulier après la 20^e époque. Cela pourrait être attribué à la taille limitée de l'ensemble de validation ou à une variabilité des données de validation. Malgré ces fluctuations, la perte de validation reste proche de la perte d'entraînement, suggérant une bonne capacité de généralisation du modèle. Les résultats indiquent que le modèle est performant, bien qu'une légère augmentation de la perte de validation à la fin de l'entraînement puisse être un signe précoce de surentraînement. Des techniques telles que le Dropout ou une augmentation de la taille de l'ensemble de validation pourraient être envisagées pour stabiliser davantage les résultats.




Figure 02

Graphe de precision (accuracy) :

Le graphique de précision montre une augmentation rapide et stable de la précision sur l'ensemble d'entraînement, atteignant un plateau autour de 96 %. La courbe de validation suit une tendance similaire, bien que des fluctuations soient observées, principalement en début d'entraînement. Cela peut être attribué à la taille limitée ou à une distribution légèrement différente des données de validation. Néanmoins, la cohérence entre les deux courbes indique

une bonne capacité de généralisation du modèle. Ces résultats confirment la performance globale du modèle, atteignant un niveau de précision élevé, ce qui le rend adapté à la tâche visée. Une amélioration potentielle pourrait inclure l'augmentation des données ou une répartition plus équilibrée des données de validation pour réduire les fluctuations.




Figure 03

5 Evaluation et test du modèle :

Dans cette partie du rapport, intitulée Évaluation et test du modèle, nous avons testé la capacité du modèle de classification de genre à prédire le sexe à partir d'une image donnée. Pour ce faire, nous avons chargé le modèle pré-entraîné `gender_classification.h5` et utilisé une fonction dédiée pour effectuer la prédiction.

Le processus a consisté à charger une image (**131370.jpg**), à la redimensionner et à la convertir en tableau numérique. Ensuite, cette image a été normalisée et formatée pour être compatible avec le modèle. Une fois les données prêtes, nous avons utilisé le modèle pour

effectuer une prédiction. Selon la sortie du modèle, nous avons classé l'image comme "Male" ou "Female".

Lors de l'exécution de cette procédure sur une image spécifique, le modèle a correctement classé l'image comme étant de genre Féminin. Ce résultat montre que le modèle fonctionne correctement pour cette image spécifique, avec une prédiction fidèle aux attentes comme il est illustré dans cette figure.



Figure 04

```
Entrée [82]: from tensorflow.keras.utils import load_img, img_to_array

img_path='C:/Users/lenovo/Desktop/archive/Validation/female/131370.jpg.jpg'

Entrée [83]: def male_or_female(img_path,model):
    img=load_img(img_path,target_size=(48,48))
    img_array=img_to_array(img)
    img_array=img_array/255.0
    new_array_with_batch_dimension=np.expand_dims(img_array,axis=0)
    output=model.predict(new_array_with_batch_dimension)
    output=np.round(output.flatten())[0]
    val="Male" if output==1 else 'Female'

    return val

Entrée [84]: male_or_female(img_path,model)

1/1 ————— 0s 25ms/step

Out[84]: 'Female'
```

Figure 05

Ce test permet de confirmer l'efficacité du modèle pour la tâche de classification de genre, bien que des tests supplémentaires sur un plus grand ensemble de données soient nécessaires pour évaluer sa robustesse et sa capacité de généralisation.

6 Conclusion

En conclusion, ce projet a démontré l'efficacité de l'intelligence artificielle, et en particulier des réseaux de neurones convolutifs (CNN), dans la classification du genre à partir d'images de visages humains. Grâce à l'utilisation d'un dataset équilibré et bien structuré, combinée à une approche rigoureuse de modélisation, nous avons obtenu des performances satisfaisantes, avec une précision globale élevée. Ces résultats soulignent le potentiel des modèles de Deep Learning dans des applications pratiques telles que l'analyse démographique, la personnalisation des services et l'amélioration de l'accessibilité.

Cependant, des défis restent à relever, notamment en ce qui concerne l'éthique et la gestion des biais pour garantir une utilisation équitable et responsable de ces technologies. Ce travail ouvre la voie à des améliorations futures, notamment en explorant des datasets plus diversifiés et en optimisant les architectures des modèles pour une meilleure généralisation.